

基于 SVM 的多变量股市时间序列预测研究

金桃¹ 岳敏² 穆进超² 宋伟国² 何艳珊² 陈毅²

¹ (吉林广播电视大学教学处理工系 吉林 长春 130022)

² (兰州大学计算机科学与工程学院 甘肃 兰州 730000)

摘 要 目前在股市时间序列预测中,大多数采用单变量时间序列预测算法,导致预测准确度不够高。提出采用基于支持向量机 SVM(Support Vector Machines)的多变量股市时间序列预测算法,来提高预测准确度。SVM 训练算法中,合适的参数可以使训练模型具有更好泛化能力。交叉验证具有指导参数选择的能力,然而考虑到交叉验证算法效率不高的问题,将其并行化,既达到了参数优选的目的,又避免了传统交叉验证效率低的问题。然后,根据较优参数建立多变量 SVM 时间序列回归预测模型,进行预测。实验证明,预测平均绝对百分比误差控制在 10% 以内,并且较之单变量的 SVM 回归预测有更好的泛化能力。

关键词 支持向量机 回归 多变量 交叉验证 并行

ON SVM-BASED MULTIVARIABLE STOCK MARKET TIME SERIES PREDICTION

Jin Tao Yue Min Mu Jinchao Song Weiguo He Yanshan Chen Yi

¹ (Department of Education Jilin Radio and TV University Changchun 130022, Jilin China)

² (School of Information Science and Engineering Lanzhou University Lanzhou 730000, Gansu China)

Abstract At present the majority of methods in stock market time series prediction are single variable time series prediction algorithms whose prediction accuracies are unsatisfied. In this paper, a multi variable stock market time series prediction algorithm based on support vectormachine (SVM) is raised for improving the accuracy of prediction. Using SVM to train the sample, proper parameters can make the training model have better generalization ability. K-fold cross validation has the ability to direct the parameter selection. However, considering the inefficiency of K-fold cross validation, parallel K-fold cross validation algorithm is proposed. In this way, we achieve the aim of parameter optimization and also avoid low efficiency of traditional K-fold cross validation. After that, the SVM multi variable time series regression model is built based on the selected parameters to carry out the prediction. Experimental results show that the prediction of mean absolute percentage error is controlled to less than 10% by this method, and its generalization ability is better than that of support vectormachines regression prediction with single variable.

Keywords Support vectormachines Regression Multi variable Cross validation Parallel

0 引 言

随着股票市场的发展,股票时间序列预测开始成为人们研究的热点。目前对于时间序列预测采用的预测方法主要有自回归模型,滑动平均模型,灰色预测法,神经网络预测法,支持向量机。支持向量机基于结构风险最小化原则,从理论上保证算法的全局最优;而且,支持向量机用核函数思想,能够解决维数灾难问题,使得计算大大简化。支持向量机 SVM 由 Vapnik 及其研究小组于 1995 年提出^[1],通过非线性变换将非线性数据转化为某个高维空间中的线性问题,被广泛用于分类、预测和回归,应用于时间序列预测研究有很好的效果。

股票数据是一种特殊的时间序列数据,其变化受各种因素的影响,因而,要对股市时间序列数据进行预测也变得比较困难。目前,有很多学者研究股市时间序列的预测,杨铎等人使用支持向量机进行股市时间序列预测^[2],然而预测准确度并不令人满意。之后又使用基于小波变换域的支持向量机进行了股市时间序列预测^[3],以提高预测准确度。姚洪兴等人使用小波神

经网络进行预测^[4]。杨一文等人。考虑用多变量的方法进行股票时间序列预测,同样采用神经网络的方法^[5],然而神经网络存在若干缺陷,比如过学习,维数灾难等。支持向量机可以解决小样本、高维度的问题。但是,目前对支持向量机回归预测的研究应用中,大多数使用单变量进行预测。而现实中,每个被预测变量是受多个变量影响的,变量之间存在相互依赖关系,仅由单一变量建立回归预测模型应用于时间序列预测并不能准确预测其变化趋势,导致预测的泛化能力受到影响。例如在气象领域、股票领域,进行预测时应该考虑多变量预测方法。文献[2-3]中使用支持向量机进行预测,然而仅仅考虑了单要素的影响,所以预测精度受到了影响。

本文提出使用多变量进行基于 SVM 的股市时间序列预测。为了保证 SVM 训练模型具有好的预测能力,我们采用交叉验证方法进行参数的优选。同时,在采用交叉验证方法时,考虑到交叉验证的效率问题,我们将交叉验证方法并行化,提高了算法的效率,从而缩短了选择参数的时间。然后采用较优参数进行训

收稿日期: 2009-07-20 金桃,副教授,主研领域:数据挖掘技术。

练,得到训练模型,最后使用训练模型进行预测。实验证明,该方法的预测准确度较之单变量预测方法的准确度有大幅度的提高,证明了该方法的合理性和有效性。

1 相关原理

1.1 支持向量机(SVM)回归原理

支持向量机是从统计学习理论发展而来的,其形式化表示为,设给定训练样本集 $G = \{ (x_i, y_i) \}_{i=1}^n$; 其中 $x_i \in R^d$ 表示第 i 个 d 维向量,称为输入特征向量。 $y_i \in R$ 表示输出, $i=1, 2, \dots, n$ 。通过训练学习寻求 R^d 上的函数 $f(x)$, 使得训练样本集要满足对任意 x_i 存在 $y_i = f(x_i)$, 对于 x_{n+1}, x_{n+2}, \dots 的数据, 也同样存在这样的 $f(x)$ 。

回归问题,是输入变量和输出变量通过函数关系表示,并以此函数为规则,通过输入新的变量,得到新的输出作为预测值。对于包含 n 个样本 $\{x_i, y_i\}_{i=1}^n$ 的训练集合,输入数据 $x \in R^d$, 输出数据 $y \in R$ 。通过求解函数 $f(x)$, 该函数能够表达 y 对 x 的依赖关系,即满足 $y = f(x)$ 。

在支持向量机回归中,输入样本首先用非线性映射映射到一个 n 维的特征空间,然后在这个特征空间中建立一个线性模型:

$$f(x, w) = w^0 \cdot \Phi(x) + b \quad (1)$$

其中, $f(x, w)$ 是估计函数; w 为权向量; $\Phi(x)$ 为输入的非线性映射集合; b 为阈值。其正确性是由损失函数来衡量的。1964年,Huber提出基于噪声模型选择损失函数的最佳方法。然而 Huber 所提出的损失函数不能使得支持向量稀疏,仍然不适用于支持向量机。为了解决这个问题, Vapnik 提出了 ϵ -不敏感损失函数:

$$\epsilon(f(x_i) - y_i) = \begin{cases} 0 & |f(x_i) - y_i| \leq \epsilon \\ |f(x_i) - y_i| - \epsilon & \text{其它} \end{cases} \quad (2)$$

如果对于每个输入向量 x_i , $f(x_i, w)$ 和 y_i 的差值很小,则认为这样的 $f(x, w)$ 能通过 x 准确的预测 y 其中 $\epsilon \geq 0$ 用来表示预测值与实际值的最大差距,该算法称为 ϵ -SVR(ϵ -Support Vector Regression)^[6-7]。本文采用 ϵ -SVR 作为预测实验中的回归算法^[8-9]。

依据结构风险最小化准则,确定系数 w 和 b 用数学语言表达,SVR 所要求解的问题是:

$$\min_{w, b} \frac{1}{2} \|w\|^2 + C \frac{1}{n} \sum_{i=1}^n L_\epsilon(y_i - f(x_i, w)) \quad (3)$$

s.t. $|y - f(x, w)| \leq \epsilon$

其中,常数 $C(C > 0)$ 用来调整训练模型,用于平衡结构风险和置信风险。

利用对偶 Lagrange 得出式(1)中的 w 可表示成 x 的线性组合:

$$f(x) = \sum_{i=1}^n (\alpha_i - \alpha_i^*) (x^0 \cdot x_i) + b \quad (4)$$

$f(x)$ 的复杂度取决于支持向量 ($\alpha_i - \alpha_i^* \neq 0$ 的项), 同时当满足 Mercer 条件时,有 $k(x, x') = \Phi(x) \cdot \Phi(x')$, $\Phi(x)$ 为将 n 维向量映射到其它维度的映射。则式(4)中 $x^0 \cdot x_i$ 项由满足 Mercer 条件的核函数 $k(x^0, x_i)$ 取代,得到:

$$f(x) = \sum_{i=1}^n (\alpha_i - \alpha_i^*) k(x, x_i) + b \quad (5)$$

本文采用径向基核函数作为支持向量机的核函数。径向基

核函数为:

$$k(x, x') = e^{-\frac{\|x - x'\|^2}{2\sigma^2}}$$

1.2 交叉验证原理

参数的取值对支持向量机有很重要的影响,选择合适的参数,能够使支持向量机既有好的学习能力,又有好的泛化能力。参数选择的方法有交叉验证法,经验公式法,遗传算法等。

交叉验证是度量 SVM 回归结果的首选方法,并且它具有指导参数选择的能力。交叉验证是在错误分析中用来估计错误率的,是由 Hills^[10]、Lachenbruch 和 Mickey^[11] 提出的。交叉验证被称为是对泛化误差的无偏估计^[12-13],是统计学习中的著名方法,其本质是通过在训练集上训练模型,使之既具有一定的训练精度,又获得良好的泛化性能。P. Jonathan 等人^[14]在预测模型的性能估计中使用了交叉验证。交叉验证分为三种,保持法、K 折交叉验证方法和弃一法交叉验证。

K 折交叉验证 (k-fold cross validation) 原理是将训练样本分成数据量相同的 k 个子集,执行训练算法 k 次。对于每个子集 i ($i=1, 2, \dots, k$), 在第 i 次训练时,要用除去第 i 个子集后的 $k-1$ 个子集作为训练集训练模型,用第 i 个子集作为测试集计算模型预测的误差。最后将 k 次预测的平均误差值作为模型的近似误差值。下面给出 K 折交叉验证算法:

输入: 数据集 D, k

输出: 平均误差

- (1) Partition (D, k);
- (2) for ($i=0 \leftarrow k, i++$) {
- (3) $T = D - D_i$; //划分 D 的子集 T 为训练集
- (4) Training (T); //训练 T
- (5) Testing(D_i, T); //使用 D_i 测试
- (6) $mean_error = \sum_{i=0}^k (|error_i - y_i|)^2$

该方法的缺点是,训练算法要进行 k 次,所以,它是非常耗时的。

2 算法以及流程

2.1 并行 K 折交叉验证方法

K 折交叉验证法广泛地应用于当前的参数选择方法中,其缺点是计算量大,当样本数很大时会存在时间效率特别低的问题。例如,我们使用 K 折交叉验证,当样本数很大,并且 k 也比较大的时候,需要训练 k 次,而每训练一次的时间代价是 $O(n^2)$,所以,提高该算法的时间效率是有必要的。交叉验证原理是将样本分成 k 组,每次训练除了测试集以外的 $k-1$ 个组,所以,每次训练是独立的,互不影响的。可以将该算法并行化。

本文提出并行化 K 折交叉验证算法 (PCV),以提高该算法的效率。该并行方法采用 MP 消息传递机制,我们将每次训练指定到一个节点进行,最后由所有从节点将结果发送到主节点,由主节点计算最终的误差。下面给出并行化 K 折交叉验证算法的形式化表述。

算法 PCV 是运行在分布式内存并行环境下的并行算法。算法中,函数 svm_train 根据参数 Param 训练数据集 $subprob$ 得到训练模型 $submodel$ 。函数 $svm_predict$ 是预测函数,返回预测值。在算法中,每个处理器 (包括处理器 0) 单独地训练分到该处理器上的训练样本子集,最后,从处理器 (从节点) 将每个子

集的训练误差值发送到处理器 0(主节点) 处理器 0 计算最终误差值。

```
PCV 算法
输入: 数据集 D, k
输出: 平均误差
(1) MPI_Comm_size(MPI_COMM_WORLD & size;
(2) MPI_Comm_rank(MPI_COMM_WORLD & myid);
(3) init i;
(4) init num;
/* 初始化 和每个节点做交叉验证的次数 num */
(5) for num>0 i++, num-- {
/* 每个组的开始和结束点在整个样本中的位置 */
(6) begin= fold_start j;
(7) end= fold_start i+1;
(8) subprob_1= 1-(end-begin);
(9) init subprob x subprob y end begin;
/* 初始化 k 折交叉验证的训练集和测试集
(10) struct svm_model* submodel= svm_train(& subprob param;
(11) for i= begin to end i++
(12) target perm[ j ] = svm_predict( submodel prob> x perm
[ j ] );
/* 将结果发送到节点 0 */
(13) if myid ==0)
MPI_Send(& result 1 MPI_DOUBLE 0 90 MPI_WORLD);
/* 节点 0 接收消息 */
(14) else
MPI_Send(& result 1 MPI_DOUBLE x 90 MPI_COMM_WORLD
& status;
(15) Calculate total error sumy sumy sumvy sumvy sumwy;
```

2.2 基于 SVM 的多变量股市时间序列预测算法

利用支持向量机进行多变量时间序列预测的思路是, 假设时间序列的预测要素 x 有在 m 个时间段内的观测值(样本), 这些观测值是由 d 个变量构成的, 则预测时间序列可以表示为:

$$Y(t) = F(X(t_0), X(t_1), \dots, X(t_{m-1}))$$

式中, $t_i = t_0 + i \Delta, i = 0, 1, \dots, m-1, X = \{x_1, x_2, \dots, x_d\}$, 则该序列是在有界可测集 T 时间坐标上的 $t_0, t_0 + \Delta, \dots, t_0 + (m-1)\Delta$ 上的可测函数 $Y(t)$ 。通过 SVM 回归模型求解 $Y(t)$ 作为根据要素 x 的 $m-1$ 个时间段历史样本, 预测 x 在 m 时刻的值的函数。

基于 SVM 的多变量股市时间序列预测算法有如下 4 个步骤:

- Step1 样本的获取与数据预处理
- 样本的性能对模型的学习有着极为重要的影响, 合适的样本能够为提高预测模型的正确率提供良好的支持。
- 我们选取股票收盘价作为被预测要素, 考虑到每日股票的收盘价同时受开盘价, 最高价和最低价的影响, 所以在预测过程中采用多变量分析和预测, 使用开盘价、最高价、最低价和收盘价四个变量, 对收盘价进行预测。
- 数据预处理主要是训练数据格式的归一化处理, 即将所有具有不同量纲指标的值规范化到 $[-1, 1]$ 区间内, 以减少训练过程中数值计算的复杂度。归一化的公式如下:

$$x'_i = \frac{x_i - x_{min}}{x_{max} - x_{min}} \tag{6}$$

其中, x_{max} 和 x_{min} 分别为样本数据中的最大值和最小值, x' 为归一化后的数据。

对于时间序列 $\{x_1, x_2, \dots, x_N\}$, 前 n 个数据作为训练样本, 后 $N-n$ 个数据作为测试集。选定时间序列的时延窗口 m 为 5 当前时刻为 t , 数据值为 x_t 的相关要素为 x'_t, x''_t 和 x'''_t , 则训练数据可表示为:

$$\begin{matrix} x_t & x_{t-1} & x_{t-2} & x_{t-3} & x_{t-4} & x'_{t-1} & x'_{t-2} & x'_{t-3} & x'_{t-4} & x''_{t-1} & x''_{t-2} \\ & x'_{t-3} & x'_{t-4} & x''_{t-1} & x''_{t-2} & x'''_{t-3} & x'''_{t-2} & x'''_{t-1} & x'''_{t-4} & & \end{matrix} \tag{7}$$

其中, x_t, x'_t, x''_t 和 x'''_t 是归一化后的数据, $t \in [t-4, t]$, x_t 是原数据。

- Step2 参数的确定
- 支持向量机能够解决有限样本和维数灾难等问题, 在预测中, 必须构造准确的 SVM 回归预测模型, 关键是选取合适的核函数和参数, 从而使训练模型具有较高的预测精度。SVM 回归预测中, 主要参数是核函数的参数 σ, ϵ, C 。文章中, 采用并行的 K 交叉验证方法进行参数选择, 以误差值最小时的参数作为较优参数。

- Step3 用训练样本数据建立模型
- 选择好参数后, 使用 SVM 方法构造回归函数 Y_t 将 m 维的输入空间变换到另一个高维特征空间, 并根据结构风险最小化原理, 综合考虑函数复杂度和回归误差, 求得最优回归曲线, 建立回归模型。

- Step4 将待预测的数据输入模型, 得到预测结果
- 使用 Step3 得到的模型, 用测试样本进行预测。本文对实验的预测结果采用如下 2 个统计量检验其拟合效果和预测效果:

(1) 均方根误差:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \tag{8}$$

(2) 平均绝对百分比误差:

$$MAPE = \frac{1}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{|y_i|} \tag{9}$$




图 1 预测流程

3 实验结果以及分析

- 实验中, 实验数据为深圳成指 2000 至 2009 年上半年的数据。选取每日收盘价作为预测数据, 实验的主要参数有时间序列的时间延迟窗口 m 核函数的参数 σ, ϵ, C
- 并行交叉验证算法是在甘肃省计算中心的曙光 4000I 超级计算机上进行的。

- 3.1 参数选择
- 参数的取值对支持向量机有很重要的影响。实验中用到的主要参数有: 时延窗口 m 和支持向量机核函数参数 δ, ϵ, C
- 给定时延窗口 $m=4$ 使用并行交叉验证方法, 得到该实验中较优的核函数参数。令 $\gamma = 1/\delta^2$ 则 $\gamma = 1, \epsilon = 0.001, C = 100$
- 取核函数参数 $\gamma = 1, \epsilon = 0.001$ 变化惩罚参数 C 值, 在实验中根据误差值变化 C 值跨度, 得到预测误差比较如表 1 所示。

表 1 预测误差随 C 值变动比较

C 值	1	10	100	200	250	300	400	500
RMSE	401.983	81.465	45.129	34.062	27.845	29.153	25.891	23.354
MAPE	0.0829	0.0147	0.0084	0.0060	0.0054	0.0050	0.0044	0.0040

由表 1 可以看出,当 C 值增大时误差逐渐减小,当 C 值在 [200 300] 区间时误差达到最小,当 C 值超过 300 后,误差不再有明显变化。且在 C 值变化中,平均绝对百分比误差始终保持在 10% 以内。

3.2 预测准确度分析

为了更好地说明采用多变量预测的合理性和准确性,采用单变量的支持向量机股市时间序列回归预测结果作为对比。取时延窗口 $m=5$ 核函数参数 $\gamma=1 \quad \epsilon=0.001 \quad C=100$ 图 2 显示了取 $N-n$ 为 57 的预测结果。图 3 显示的是随机从样本中选取一个测试集,剩下的作为训练集的预测结果。由图 2 和图 3 可以看出,采用多变量进行预测后,预测准确度得到了大幅度的提高,证明了该方法在预测精度方面的优越性。




图 2 股市时间序列预测曲线

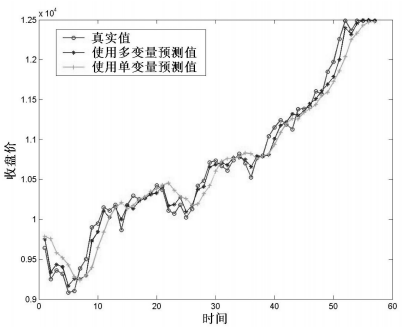


图 3 股市时间序列预测曲线

同时,我们考查了预测的均方根误差随 C 值变化的情况。图 4 说明了均方根误差随 C 值变化的曲线。




图 4 均方根误差随 C 值变化的曲线

由图 4 可以看出,当 C 值大于等于 100 时,均方根误差变化减小,趋于稳定。所以,在实验中取 C 值为 100 即可以满足训

练质量要求。

实验结果表明,采用多变量的支持向量机进行股票时间序列预测时,可以将误差控制在较小的范围内。采用该方法的泛化能力要强于单变量的 SVM 回归预测。

3.3 相对加速比分析

为了度量相对加速比,在实验中保持数据集不变,改变节点数目。具有 P 个节点的相对加速比的度量方法如下:

相对加速度 (P) = $\frac{\text{并行程序在一个节点上的运行时间}}{\text{并行程序在 P 个节点上的运行时间}}$ (10)

对于样本数据集,我们选择三个不同大小的数据集测试相对加速度,从图 5 可以看出,随着节点数目增加,相对加速度先呈增长趋势,然后又下降趋势。最高的相对加速度值为 9.08 证明了该方法在时间方面的优越性。相对加速度值下降是由于当节点数目增大时,节点间消息传递时间占总运行时间的比例较大,所以相对加速度值出现了下降趋势。对于数据集 data1 和 data2,当节点数增加到 8 时,出现下降趋势;而数据集 data3,当节点数增加到 7 时,就有下降趋势,是由于数据集 data3 数据量最小的原因。综上分析,对于数据量比较大的情况,并行 K 折交叉验证方法可以显示其优越性。




图 5 相对加速度值曲线

4 总 结

大多数时间序列数据的外部控制因素多变,包括股市时间序列,因此,仅仅依靠单一变量进行时间序列分析与预测并不能很好地预测出时间序列的变化趋势。本文提出应用多变量进行基于 SVM 的股市时间序列预测,建立多变量的支持向量机时间序列回归预测模型,优点是使用多变量进行预测,较之单变量预测具有高的精确度,另外使用并行 K 折交叉验证方法缩短了选择参数时间,实验显示出了较好的预测效果。今后工作主要致力于 SVM 训练方法的并行化研究,以提高训练的时间效率。

参 考 文 献

[1] Vapnik V N The Nature of Statistical Learning Theory [M]. N Y Springer-Verlag 1995.
[2] 杨钰,史耀媛,宋恒. 基于支持向量机的股市时间序列预测算法 [J]. 科学技术与工程, 2008 8(2): 381—386
[3] 杨钰,史耀媛. 基于小波变换域的 SVM 股市时间序列预测算法 [J]. 科学技术与工程, 2008 8(2): 3171—3175
[4] 姚洪兴,盛昭瀚. 股市预测中的小波神经网络方法的研究 [J]. 管理工程学报, 2002 16(2): 32—37

(下转第 209 页)

统来说, 实体的动力学仿真可以忽略, 看中的是视景仿真效果, 因此导演台发送的是非连续的数据, 而是直接发送某一时刻实体的姿态数据。视景机把数据直接赋给实体看不到实体航向效果和海面转动效果, 因此本文采用了二次插值算法。插值计算获得的航向是在线程中实现的, 通过调用 `vpObject` 类的库函数完成实体的实时运动。

3) 目标的状态效果 主要分为爆炸、着火、冒烟、正常。根据导演台发送的目标状态显示相应的特效。文中在 `LMX` 中预先为每个目标 `Object` 设置了爆炸、着火、冒烟特效, 在系统运行过程中通过调用 `vpExplosion` `vpFire` `vpSmoke` 类库进行设置^[7-8]。

1.4.2 潜望镜逻辑解算与光学效果仿真

用单片机进行逻辑操作的实现过程是非常复杂的, 因此单片机的所有按键编码和值都通过串口发送给视景计算机, 由计算机进行逻辑运算。运算结果通过视景显示出来, 潜望镜的逻辑操作主要是光学仪器的操作, 因此需要在视景中实现光学的某些效果。主要包括: 倍率、滤光片、光学切入等。

潜望镜模拟器的逻辑操作流程非常简单, 如测距前首先“复位”, 输入“目标桅高”, 调整倍率为 6 倍, 进行“切入”, 按压“瞄准”获得目标距离, 逻辑解算通过建立一个多叉树提高效率, 并行操作为同一个根节点的树枝。因此重点是根据潜望镜模拟器的操纵情况实现相应的光学效果。如图 3 和图 4 显示的倍率在 6 倍的情况下, 滤光片分别为黄色、变暗状态时进行切入后在潜望镜镜头看到的视景效果。



图 3 光学操作效果一



图 4 光学操作效果二

1) 倍率的控制 实现场景的放大和缩小, 在视觉上达到通过镜片观察的效果。本文通过调用 VegaPrime 的 `vpChannel` 类库的 `setFOVSymmetric` 函数设置视野大小来实现。

2) 滤光片设置 滤光片主要分为明、暗、黄三种颜色, 用 GLStudio 分别制作三种颜色的背景, 然后通过 `vpGLStudio` 类将背景加载到场景中对其进行控制。

3) 光学切入 切入的现象是将观察的目标推开, 根据目标的桅高、像高和焦距计算目标的距离。采用双通道来实现, 设置

两个通道的范围大小分别为 0 到 0.5 和 0.5 到 1, 错开的大小通过设置其中一个通道的俯仰角进行实现。

2 结 论

本文在研究了建模和显示的关键技术和方法的基础上, 建立了基于 VegaPrime 的潜艇攻防的潜望镜视景仿真训练系统, 解决了潜望镜模拟器和视景的交互、目标的实时控制与逻辑操作仿真、光学效果的仿真等问题, 满足了潜望镜操作训练的环境要求。由于采用了优化的模型数据库结构和调用方式, 系统资源分配合理。通过实验表明, 该视景系统具有较好的实时交互性、可靠性和真实沉浸感, 能很好地满足潜望镜操作人员的要求。

参 考 文 献

- [1] 吴家铸. 视景仿真技术及应用 [M]. 北京: 西安电子科技大学出版社, 2001
- [2] 胡文辉, 裴丽华. 基于 Vega 的飞机防滑刹车系统视景仿真 [J]. 系统仿真学报, 2006, 8(18): 451-453
- [3] 樊世友. GLStudio 软件在视景仿真建模中的应用 [J]. 计算机工程, 2002, (3): 260-261.
- [4] 孙崇波, 唐永刚, 等. 基于 Creator/VegaPrime 的虚拟航母漫游设计 [J]. 计算机仿真, 2007, 1(24): 222-224
- [5] 李军, 王绍棣, 等. 基于 Vega 的视景驱动软件的分析与设计 [J]. 系统仿真学报, 2003, 15(3): 397-400
- [6] 付超, 等. 基于 ActiveX 的虚拟控制系统通用集成平台研究 [J]. 系统仿真学报, 2008, 09(18): 2451-2454
- [7] MultiGen-Paradigm Inc. VegaPrime Programmer's Guide Version 2.0 [M]. USA: MultiGen-Paradigm Inc. 2005
- [8] MultiGen-Paradigm Inc. VegaPrime Options Guide Version 2.0 [M]. USA: MultiGen-Paradigm Inc. 2005

(上接第 194 页)

- [5] 杨一文, 刘贵忠. 基于神经网络的多变量时间序列预测及其在股市中的应用 [J]. 信息与控制, 30(5): 413-417
- [6] 张学工. 关于统计学习理论与支持向量机 [J]. 自动化学报, 2000, 126(1): 37-40
- [7] Steve R Gunn. Support Vector Machines for Classification and Regression [J]. SIS Technical Report 1998
- [8] 洗广铭, 曾碧卿. 支持向量回归机算法及其应用 [J]. 计算机工程与应用, 2008, 44(17): 40-42
- [9] 苏高利, 邓芳萍. 关于支持向量回归机的模型选择 [J]. 科技通报, 2006, 22(2): 156-157.
- [10] Hills M. Allocation rules and their error rates (with discussion) [J]. Journal of the Royal Statistical Society, Series B, 1966
- [11] Lachenbruch P A, Mickey M R. Estimation of error rates in discriminant analysis [J]. Technometrics, 1968, 10: 1-11
- [12] Lee M M, S Keerthi S S, Ong C J et al. An Efficient Method for Computing Leave-one-out Error in Support Vector Machines with Gaussian Kernels. IEEE Trans on Neural Networks, 2004 [C], 15(3): 750-757
- [13] Du H F, Gong M G, Jiao L C et al. A Novel Artificial Immune System Algorithm for High-dimensional Function Numerical Optimization [J]. Progress in Natural Science, 2005, 15(5): 463-471.
- [14] Jonathan P Kuzanowski W J McCarthy V. On the use of cross validation to assess performance in multivariate prediction [J]. Statistics and Computing, 2000, 10: 209-229, 28: 1-31